ENCG Settat

Détection d'anomalies sur le S&P 500

Projet F7 – Isolation Forest et Local Outlier Factor

Doha Ouhaddi et Imane Mataoui

November 8, 2026

Résumé

Ce rapport identifie les séances du S&P 500 statistiquement atypiques à l'aide de deux méthodes non supervisées, Isolation Forest (IF) et Local Outlier Factor (LOF), appliquées aux rendements logarithmiques et à la volatilité glissante sur 20 jours. Les anomalies sont ensuite comparées à des événements de marché documentés. Sur 2492 séances (2016-12-07 à 2026-11-05), IF et LOF signalent respectivement 50 et 50 séances, dont 35 en commun. L'évaluation reste qualitative, faute d'étiquettes.

Table des matières

1 Introduction et question de recherche **2**

2 Données **2**
2.1 Source 2
2.2 Base de données produite 2
2.3 Prétraitement 2
2.4 Statistiques descriptives 2

3 Méthodes **3**
3.1 Isolation Forest 3
3.2 Local Outlier Factor 3
3.3 Seuil 3

4 Résultats **4**
4.1 Séances détectées 4
4.2 Accord entre les deux méthodes 5
4.3 Comparaison avec des événements documentés 5
4.4 Sensibilité au seuil 6

5 Discussion **6**

6 Conclusion **7**

1 Introduction et question de recherche

Quelles journées de marché sont statistiquement atypiques, et correspondent-elles à des événements connus ? La question est utile en gestion des risques (identifier des régimes de stress), en backtesting (isoler les séances qui dominent la performance) et pour tester l'hypothèse de normalité des rendements. L'approche est non supervisée : aucune séance n'est étiquetée « anomalie » à l'avance.

2 Données

2.1 Source

Les données proviennent de FRED (Federal Reserve Bank of St. Louis), série `SP500` : valeur de clôture quotidienne de l'indice S&P 500, hors dividendes. FRED ne publie que les dix dernières années de cette série (licence S&P Dow Jones Indices). Le fichier brut compte 2609 lignes, dont 96 valeur(s) manquante(s) (jours fériés, codés « . » par FRED), supprimées.

2.2 Base de données produite

Le script `f7_pipeline.py` construit une base SQLite `sp500_anomalies.db` avec les tables suivantes :

- `prices` : date et clôture brute ;
- `features` : rendement log., rendement absolu, volatilité 20 j annualisée, scores et drapeaux IF/LOF ;
- `anomalies` : séances signalées par au moins une méthode ;
- `events` : événements documentés et détection par chaque méthode ;
- `summary` et `sensitivity` : indicateurs globaux et analyse de sensibilité.

2.3 Prétraitement

Le rendement logarithmique est $r_t = \ln(P_t/P_{t-1})$. La volatilité glissante annualisée est

$$\sigma_t = \sqrt{252}\ \mathrm{std}(r_{t-19}, \ldots, r_t)\,.$$

Après suppression des 20 premières observations (fenêtre de volatilité), il reste 2492 séances. Les deux variables sont standardisées avant l'application des algorithmes.

2.4 Statistiques descriptives

Le rendement quotidien moyen est de 0.048 % pour un écart-type de 1.150 %. L'asymétrie vaut -0.69 et le kurtosis en excès 16.48 (0 pour une loi normale). Le rendement minimal est de -12.77 % et le maximal de 9.09 %.

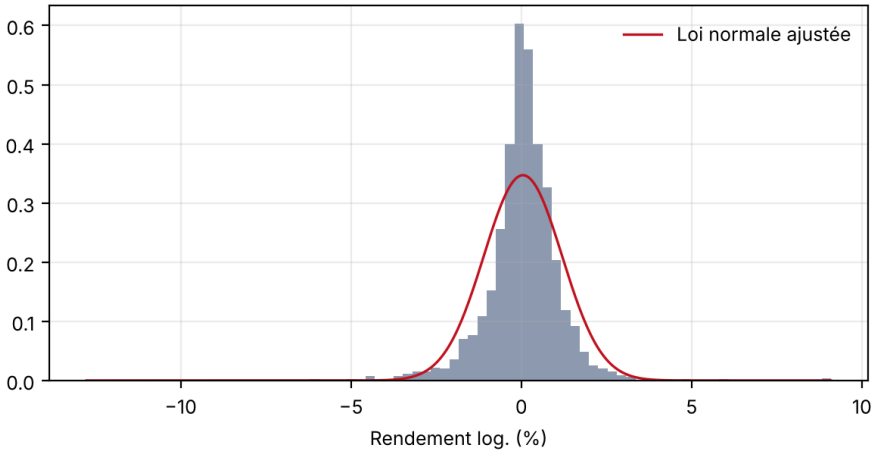


Figure 1: Distribution des rendements quotidiens et loi normale ajustée.

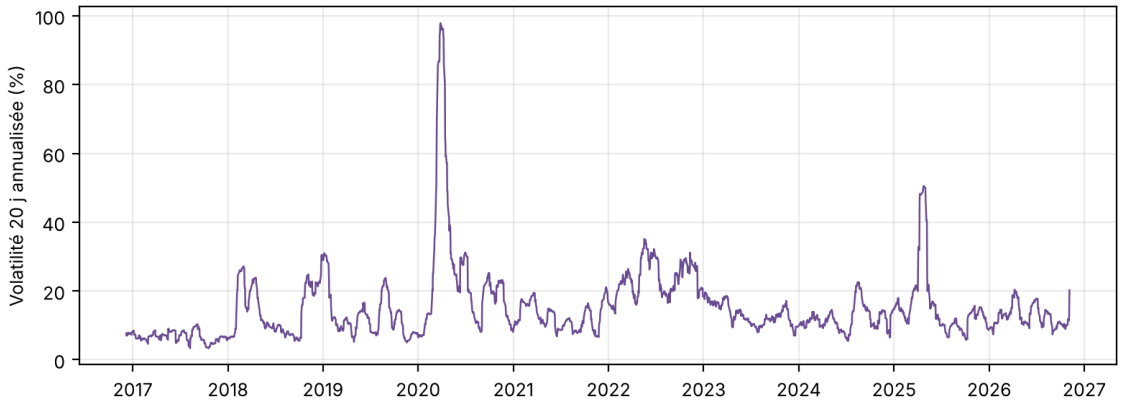


Figure 2: Volatilité réalisée sur 20 jours (annualisée).

3 Méthodes

3.1 Isolation Forest

IF isole les observations par partitions aléatoires successives : une observation atypique est isolée en peu de coupures, donc avec une faible profondeur moyenne dans les arbres. Le score d'anomalie croît quand la profondeur moyenne diminue. Paramètres : 300 arbres, `random_state`=42.

3.2 Local Outlier Factor

LOF compare la densité locale d'une observation à celle de ses k plus proches voisins ; un rapport nettement supérieur à 1 signale une anomalie locale. Paramètre : $k = 30$.

3.3 Seuil

Les deux méthodes exigent une proportion attendue d'anomalies (*contamination*). Le cas de base retient 2 %, soit environ 50 séances ; l'analyse de sensibilité teste 1 %, 2 % et 5 %.

4 Résultats

4.1 Séances détectées



Figure 3: Cours du S&P 500 et séances signalées par IF, LOF ou les deux.

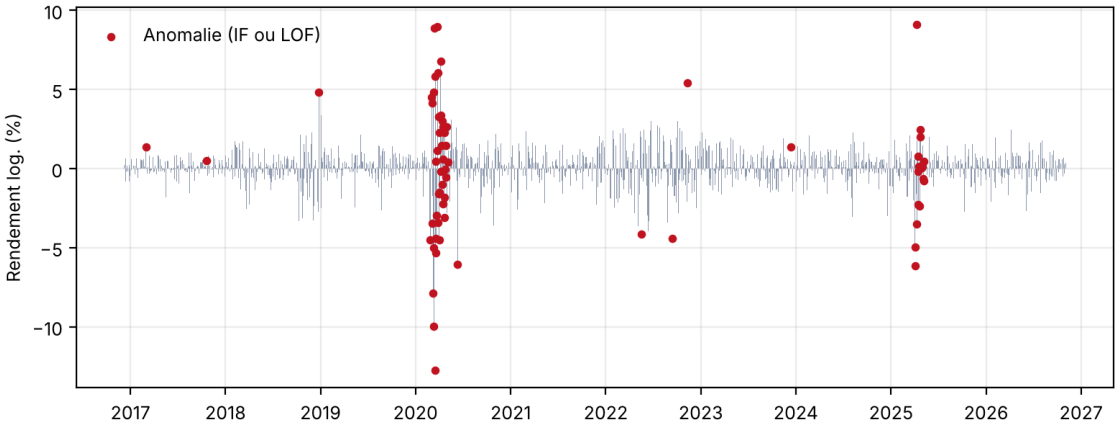


Figure 4: Frise chronologique des rendements quotidiens et des anomalies (IF ou LOF).

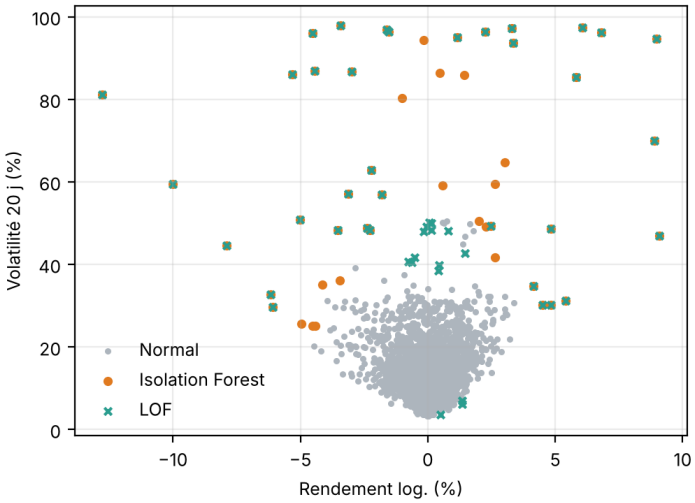


Figure 5: Espace des variables : rendement et volatilité 20 j.

Date	Rend. (%)	Vol. 20 j (%)	IF	LOF
2020-03-24	8.97	94.6	✓	✓
2020-04-06	6.80	96.2	✓	✓
2020-03-26	6.05	97.4	✓	✓
2020-03-16	-12.77	81.1	✓	✓
2020-04-01	-4.51	96.0	✓	✓
2020-03-17	5.82	85.4	✓	✓
2020-03-18	-5.32	86.1	✓	✓
2020-03-13	8.88	70.0	✓	✓
2020-03-20	-4.43	86.8	✓	✓
2020-03-27	-3.43	97.9	✓	✓
2020-03-30	3.30	97.1	✓	✓
2020-04-08	3.35	93.7	✓	✓
2020-03-12	-9.99	59.5	✓	✓
2020-04-02	2.26	96.3	✓	✓
2020-03-23	-2.97	86.8	✓	✓

Tableau 1: Quinze séances au score IF le plus élevé.

4.2 Accord entre les deux méthodes

IF et LOF partagent 35 séances, soit un indice de Jaccard de 53.8 %. Les deux méthodes ne mesurent pas la même chose : IF est sensible aux valeurs extrêmes globales, LOF aux écarts de densité locale. Un accord partiel est donc attendu, et les séances communes sont les plus robustes.

4.3 Comparaison avec des événements documentés

Le tableau 2 rapproche les anomalies d'une liste d'événements de marché documentés, avec une tolérance de ±2 séances. Parmi les événements inclus dans la période, IF en détecte 80.0 % et LOF 73.3 %. Inversement, 44.0 % des anomalies IF et 38.0 % des anomalies LOF tombent près d'un événement de la liste, contre 2.4 % des séances au hasard : cette comparaison donne un repère, pas un test statistique.

Date	Événement	IF	LOF
2018-02-05	Volmageddon : forte hausse de la volatilité (VIX)	×	×
2018-12-24	Creux de fin 2018 (resserrement de la Fed)	✓	✓
2018-12-26	Rebond record de fin 2018	✓	✓
2020-03-09	COVID-19 : krach pétrolier et pandémie, coupe-circuit	✓	✓
2020-03-12	COVID-19 : pire séance depuis 1987	✓	✓
2020-03-16	COVID-19 : baisse de plus de 10 %	✓	✓
2020-03-24	COVID-19 : rebond après le plan de soutien	✓	✓
2020-06-11	Craintes d'une seconde vague COVID-19	✓	✓
2020-11-09	Annonce du vaccin Pfizer-BioNTech	×	×
2022-09-13	Inflation américaine (CPI) supérieure aux attentes	✓	×
2022-11-10	Inflation (CPI) inférieure aux attentes, rebond	✓	✓
2024-08-05	Débouclage du carry trade sur le yen	×	×
2025-04-03	Annonce des droits de douane 'Liberation Day'	✓	✓
2025-04-04	Poursuite de la chute après les droits de douane	✓	✓
2025-04-09	Pause de 90 jours sur les droits de douane, rebond	✓	✓

Tableau 2: Événements de marché documentés et détection (✓ détecté, × manqué, n.d. hors période).

4.4 Sensibilité au seuil

Contam.	n_{IF}	n_{LOF}	Jaccard	Rappel IF	Rappel LOF
1 %	25	25	38.9 %	33 %	73 %
2 %	50	50	53.8 %	80 %	73 %
5 %	125	125	52.4 %	93 %	87 %

Tableau 3: Effet de la contamination sur le nombre d'anomalies, l'accord IF/LOF et le rappel d'événements.

5 Discussion

Ce que montrent les résultats. Les anomalies sont très concentrées : sur les 65 séances signalées par au moins une méthode, 42 sont en 2020 (mars-avril, COVID-19), 16 en 2025 (droits de douane), 3 en 2022, 2 en 2017, 1 en 2018 et 1 en 2023. Les quinze scores les plus élevés sont tous en mars-avril 2020, quand la volatilité 20 j annualisée atteint 60 à 98 % et que les rendements atteignent $-12{,}8\,\%$ (16 mars) et $+9{,}0\,\%$ (24 mars). La volatilité étant persistante, les séances extrêmes arrivent en grappes, pas isolées. Les rendements sont loin de la loi normale : kurtosis en excès de 16.48 et asymétrie négative de -0.69.

Événements détectés et manqués. IF détecte 12 des 15 événements de la liste, LOF 11. Les trois ratés communs sont le Volmageddon (5 février 2018), l'annonce du vaccin (9 novembre 2020) et le débouclage du yen (5 août 2024). Ce sont des chocs courts, survenus quand la volatilité 20 j était encore basse : le couple rendement-volatilité n'y est pas assez rare pour être isolé, surtout après le COVID-19 qui tire la distribution vers le haut. Seul le 13 septembre 2022 (inflation) est détecté par IF et pas par LOF.

Sensibilité. À 1 % de contamination, IF ne retrouve plus que 33 % des événements contre 73 % pour LOF ; à 2 % et 5 %, IF fait aussi bien ou mieux (80 % puis 93 %). Le choix du seuil change donc nettement la conclusion, ce qui justifie l'analyse de sensibilité.

Limites.

- **Absence d'étiquettes** : l'évaluation par événements est subjective, et la liste d'événements est choisie par l'auteur. Elle devrait être complétée et sourcée (presse financière, communiqués de la Fed).

- **Profondeur historique** : dix ans seulement, avec un épisode dominant (COVID-19, mars 2020) qui pèse sur les résultats.
- **Standardisation sur l'échantillon complet** : l'analyse est rétrospective. En usage temps réel, il faudrait standardiser avec une fenêtre passée pour éviter une fuite d'information future.
- **Seuil de contamination** : le nombre d'anomalies est fixé par hypothèse, non estimé.
- **Indice de prix** : hors dividendes ; les rendements ne sont pas des rendements totaux.

6 Conclusion

Isolation Forest et LOF identifient des séances atypiques qui coïncident largement avec les grandes crises (COVID-19 en 2020, droits de douane en 2025) : 80 % des événements documentés pour IF et 73 % pour LOF à 2 %. Les deux méthodes ne se recouvrent qu'à 54 % et ratent les chocs brefs survenus en période calme ; le résultat dépend du seuil retenu. Le résultat est une aide à la détection, à valider par une analyse qualitative, et non un test d'hypothèse. Extensions possibles : autres variables (volume, VIX), fenêtre glissante pour une détection en temps réel, comparaison avec un seuil statistique simple (*z-score* robuste).

Références

- S&P Dow Jones Indices LLC, S&P 500 [SP500], FRED, Federal Reserve Bank of St. Louis, `https://fred.stlouisfed.org/series/SP500`.
- Liu, F. T., Ting, K. M., Zhou, Z.-H. (2008). Isolation Forest. *IEEE ICDM*.
- Breunig, M. M., Kriegel, H.-P., Ng, R. T., Sander, J. (2000). LOF: Identifying Density-Based Local Outliers. *ACM SIGMOD*.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*, 12.